

PRM 评分能否预测推理步骤的可删除性？

基于 PRM800K 的反事实步骤删除研究

作者: ZHANG RUICHEN

单位: The Hong Kong University of Science and Technology

更新版本: 补充分层 target-step cluster bootstrap 与 length-matched Placebo Deletion 实验结果。

摘要

Process Reward Model (PRM) 通常用于评价一个推理步骤是否局部正确、合理或存在错误。然而, reasoning-step pruning 真正需要判断的是另一个问题: **该步骤是否为后续推理所必需, 或者能否在不损害最终答案的情况下被删除。**

本项目研究 PRM step rating 与 reasoning-step removability 之间的关系。我们从 PRM800K 中抽取 600 个目标步骤, 其中 rating $(=1, 0, -1)$ 各 200 个, 并对每个步骤构造 Control 与 Deletion 两种 continuation 条件。Control 保留目标步骤, Deletion 删除目标步骤后从相同位置重新生成后续推理。每个样本运行 4 次, 共得到 2,400 组 paired observations 和 4,800 次生成。

项目进一步将步骤划分为 **Essential**、**Redundant** 和 **Harmful** 三类, 用于刻画步骤在完整推理中的功能贡献。初步结果显示, PRM rating 与步骤贡献存在较强关联, 但两者并不等价。Human-calibrated annotation 中, 34.5% 的样本属于 off-diagonal cases。删除收益主要集中在 Harmful steps, 尤其是 PRM rating $(=-1)$ 且被判定为 Harmful 的步骤; 相反, rating $(=0)$ 且被判定为 Essential 的步骤在删除后表现出明显的准确率下降。

Target-step cluster bootstrap 进一步显示, 删除效应随 step position、step length、prefix length 和 Control 稳定性显著变化。Length-matched Placebo Deletion 在 511 个可匹配 target steps 上得到总体 Target Effect $(=+7.97)$ pp、Placebo Effect $(=-0.57)$ pp、Pure Semantic Effect $(=+8.55)$ pp; 在最关键的 rating $(=-1) \times$ Harmful 组中, Pure Semantic Effect 为 $(+13.85)$ pp。这表明主要删除收益不能仅由随机删除等长内容解释。

本项目的核心结论不是 “PRM 无法反映步骤价值”, 而是:

PRM rating 是预测 reasoning-step contribution 的有用先验, 但不足以单独决定一个步骤是否应该被删除。

1. 研究背景与动机

随着大语言模型生成的推理轨迹不断变长, 推理过程中的重复、无效和误导性步骤也越来越多。为了降低推理成本并提升过程可解释性, 一个自然方向是对 reasoning trace 进行 step-level pruning。

现有 PRM 主要回答:

当前步骤是否局部正确、合理或高质量?

但 pruning system 实际需要回答:

如果删掉当前步骤, 模型是否仍然能够得到正确答案?

这两个问题并不相同。

一个局部正确的步骤可能只是:

- 重复已有结论;
- 对前文进行等价改写;
- 给出不影响后续推理的额外解释;
- 重复验证一个已经确定的结果。

这类步骤虽然正确, 但可能是可删除的。

另一方面, 一个评分较低的步骤也可能包含:

- 后续使用的变量定义;
- 必要的中间计算;
- 问题分解结果;
- 关键约束;
- 从一个推理阶段过渡到下一阶段的桥梁。

因此, 局部不完美并不必然意味着可以删除。

更进一步, 一些错误步骤会将模型锚定在错误分支上, 使后续模型不断延续或合理化该错误。如果删除这些步骤, 模型反而可能重新生成一条更正确的 continuation。

由此，本项目关注 **Step Correctness** 与 **Step Contribution** 的区别，并通过实际删除干预测量 reasoning step 对后续生成的影响。

2. 核心研究问题

RQ1: PRM rating 与 reasoning-step removability 之间存在多强的关联?

研究 rating (=1,0,-1) 的步骤在删除后分别表现出怎样的:

- accuracy change;
- Correct () Wrong rate;
- Wrong () Correct rate;
- token change;
- abnormal continuation rate.

RQ2: 哪些步骤体现了 PRM rating 与 functional contribution 的错位?

重点研究以下 off-diagonal cases:

- rating (=1) 但 Redundant;
- rating (=0) 但 Essential;
- rating (= -1) 但并非 Harmful;
- 相同 PRM rating 下具有完全不同删除效果的步骤。

RQ3: Essential、Redundant、Harmful 分类是否比 PRM rating 更接近真实删除效果?

比较:

- PRM rating;
- AI 标注的 step type;
- human-calibrated step type;
- 实际 deletion outcome.

研究哪种信号更适合:

- pruning candidate ranking;
- harmful-step detection;
- safe compression;
- dangerous deletion prevention.

RQ4: 删除步骤能否同时改善准确率和推理效率?

研究删除是否能够:

- 减少总生成 token;
- 降低 cannot continue 或 logical break;
- 保持正确答案;
- 修复原本错误的推理路径。

3. 与 PRM 和 PAV 的区别

方法	核心问题	干预或比较方向	主要对象
PRM	当前步骤是否局部正确或合理?	通常无显式 counterfactual intervention	Step correctness
PAV	加入当前步骤后，未来成功率增加多少?	Prefix () Prefix + Step	Prospective advantage
本项目	已有步骤被删除后，后续推理是否受损或改善?	Prefix + Step () Prefix without Step	Retrospective removability

PAV 与本项目都研究步骤对未来成功的贡献，但条件状态和干预方向不同。

PAV 更接近:

$$[V(h_{\{<t\},s_t}) - V(h_{\{<t\}})]$$

本项目实际测量的是:

$$[Y(h_{\{<t\}}) - Y(h_{\{<t\},s_t})]$$

其中 (Y) 表示从给定 visible prefix 出发重新生成后得到正确答案的结果。

因此，两者相关，但不应被视为完全相同的量。

4. 核心假设

H1: PRM rating 与 removability 相关, 但不等价

预计 rating 越低, 步骤越可能是 Harmful; rating 越高, 步骤越可能是 Essential。但由于冗余、重复和上下文依赖, 仍会存在大量 off-diagonal cases。

H2: Harmful steps 是最有价值的删除对象

错误步骤可能形成 reasoning anchor, 使模型继续沿错误路径生成。删除后, 模型有机会重新规划, 从而出现:

[]

H3: 正确步骤不一定是必要步骤

部分 rating (=1) 的步骤即使完全正确, 也可能不提供独特信息, 因此可以被视为 compression candidates。

H4: 低评分步骤不一定可以安全删除

部分 rating (=0) 或 (-1) 的步骤可能承载后续所需信息。仅根据 PRM rating 直接删除会产生 Correct () Wrong 风险。

H5: PRM 应作为 ranking prior, 而不是 hard deletion rule

更可靠的 pruning system 应结合:

- PRM rating;
 - contribution type;
 - prediction confidence;
 - downstream validation;
 - rollback mechanism.
-

5. 操作性定义

5.1 目标样本

每个目标样本包含:

- 问题 (q);
- 目标步骤之前的 reasoning history ($h_{\{<t\}}$);
- 目标步骤 (s_t);
- 目标步骤之后的原始 reasoning;
- PRM rating ($r_t \{-1,0,1\}$).

5.2 Control condition

模型输入:

[q, $h_{\{<t\}}$, s_t]

随后从目标步骤之后重新生成 continuation。

5.3 Deletion condition

模型输入:

[q, $h_{\{<t\}}$]

目标步骤 (s_t) 被删除, 模型从该位置重新生成 continuation。

5.4 实验实际测量的量

本实验不是从一个固定完成的答案中机械删除一句话, 而是让模型从不同 visible prefix 重新生成。

因此, 本项目测量的是:

目标步骤对新 continuation 的 contextual contribution。

它不等价于“删掉完整答案中的一句话后, 剩余文本是否仍然逻辑连贯”。

5.5 Paired outcome

每个 Control/Deletion pair 根据最终答案得到四种结果:

Control	Deletion	解释
Correct	Correct	删除后仍然成功
Correct	Wrong	删除造成损害
Wrong	Correct	删除修复错误路径
Wrong	Wrong	两种条件均未得到正确答案

6. Step Contribution 分类

6.1 Essential

目标步骤提供后续推理所依赖的关键信息，例如：

- 变量或符号定义；
- 必要中间结果；
- 问题分解；
- 关键约束；
- 重要策略选择；
- 后续推理所需的逻辑桥梁。

6.2 Redundant

步骤本身可能正确，但没有提供独特信息，例如：

- 重复前文；
- 等价改写；
- 多余解释；
- 重复验证；
- 后续未使用的计算。

6.3 Harmful

步骤引入错误或误导信息，例如：

- 错误计算；
- 错误假设；
- 无效策略；
- 与问题无关的推导；
- 导致模型继续沿错误分支生成的中间结论。

6.4 Removable label 与 Step Type 的区别

Step Type 是语义分类；Removable label 是对删除安全性的预测。

二者不完全相同：

- Redundant 通常应更容易删除；
- Harmful 删除后可能改善结果；
- Essential 通常应被保护；
- 但实际删除效果仍受到模型随机性、prefix 状态和重新生成能力影响。

因此，语义标签只能作为候选信号，最终仍需通过 intervention 评估。

7. 数据集与采样

7.1 数据集

使用 OpenAI PRM800K Phase 2 test split。

7.2 样本规模

共抽取 600 个 target steps：

- PRM rating (=1): 200 个；
- PRM rating (=0): 200 个；
- PRM rating (=−1): 200 个。

每组覆盖：

- Early position；
- Middle position；

- Late position。

7.3 建议记录的控制变量

- target step token length;
- visible prefix length;
- trajectory total length;
- step position;
- problem type;
- 原始 trajectory correctness;
- 同一问题或轨迹是否出现多个目标步骤。

8. 标注流程

8.1 Initial annotation

- DeepSeek V4 Flash 标注 415 个步骤;
- DeepSeek V4 Pro review 185 个不确定或冲突案例;
- 输出:
 - Removable label;
 - Step Type;
 - Confidence;
 - Reason。

8.2 Human calibration

从额外的 150 个 steps 中人工标注 75 个 examples，作为 few-shot demonstrations。

随后 DeepSeek V4 Flash 对全部 600 个步骤进行 blind re-label：

- 不看到旧标签;
- 不看到 deletion outcomes;
- 不使用 PRM rating 作为显式判断依据。

8.3 Annotation-level analysis

Human-calibrated labels 的分布为：

PRM Rating	Essential	Redundant	Harmful	Total
1	118	69	13	200
0	55	115	30	200
-1	25	15	160	200

关联统计：

- Pearson correlation: 0.599;
- ($\chi^2(4)=334.93$);
- ($p<0.001$);
- Cramer’s $V(=0.528)$;
- Diagonal cases: 393/600 (65.5%);
- Off-diagonal cases: 207/600 (34.5%)。

这表明 PRM rating 与 Step Type 有较强关联，但仍有超过三分之一的样本不能由 rating 直接推断其 contribution type。

9. 删除实验设置

9.1 生成模型

Qwen3-8B。

9.2 生成参数

Control 与 Deletion 使用匹配设置：

- temperature ($=0.7$);
- top-p ($=0.8$);
- max tokens ($=2048$);
- /no_think。

9.3 重复次数

每个 sample 进行 4 次 paired runs:

[600=2400]

共得到:

- 2,400 paired observations;
- 4,800 generations.

9.4 评价模型

使用 Qwen3-8B judge, 在 temperature (=0) 下判断 final answer 与 ground truth 是否 mathematically equivalent.

10. 双层分析口径

最新报告排除了 670 个 Control 与 Deletion 均错误的 Still Wrong pairs。该筛选有助于分析 “至少一个条件能够解出的样本”，但它使用了实验结果本身，因此不能替代全量数据上的 treatment effect。

本项目应明确区分两种分析。

10.1 Primary analysis: 全量 2,400 pairs

全量分析用于估计 unconditional deletion effect。

主要指标:

- overall accuracy change;
- Correct () Wrong;
- Wrong () Correct;
- Still Correct;
- Still Wrong;
- total token change;
- completion abnormality.

这是论文主结果应采用的口径。

10.2 Secondary diagnostic analysis: retained 1,730 pairs

排除:

[670]

保留:

[1730]

该分析用于回答:

当至少一个 condition 可以正确解题时，删除与保留目标步骤的表现有什么差异？

该口径适合:

- 分析 recoverable cases;
- 分析 rating 和 Step Type 的 diagnostic pattern;
- 对比 deletion harm 与 recovery;
- 研究 token 和 completion status.

但 retained accuracy 是条件性 descriptive statistic，不能被解释为全体样本上的绝对准确率。

11. 评价指标

11.1 Accuracy metrics

Unconditional accuracy change

[$\{i=1\}^N (Y_{i0}-Y_{i1})$]

Safe deletion rate

[$P(Y_{i0}=1|Y_{i1}=1)$]

Deletion harm rate

[$P(Y_{i0}=0|Y_{i1}=1)$]

Recovery rate

[$P(Y_{\text{}}=1|Y_{\text{}}=0)$]

11.2 Token metrics

定义:

[= -]

同时报告:

- total token saving;
- mean token saving;
- median token saving;
- deletion shorter / equal / longer counts;
- token saving conditioned on correctness;
- accuracy–token trade-off。

11.3 Completion metrics

- Completed;
- Cannot Continue;
- Logical Break;
- newly induced abnormal outcomes;
- recovered abnormal outcomes。

11.4 Annotation metrics

- PRM rating × Step Type;
- off-diagonal rate;
- removable prediction confusion matrix;
- precision;
- recall;
- specificity;
- F1-score。

12. 初步实验结果

12.1 全量 2,400 pairs: unconditional results

Metric	Control	Deletion	Change
Correct Answers	1,353 / 2,400	1,526 / 2,400	+173
Accuracy	56.38%	63.58%	+7.20 pp
Average Visible Tokens	326.36	313.38	–12.98
Total Visible Tokens	783,264	752,108	–31,156 (–3.98%)

Paired transitions:

Transition	Count	Share
Wrong () Correct	377	15.71%
Correct () Wrong	204	8.50%
Still Correct	1,149	47.88%
Still Wrong	670	27.92%

净准确答案增量为:

[377-204=173]

这说明删除并非单纯压缩操作。在部分样本中，删除目标步骤会移除错误 reasoning anchor，使模型重新生成正确路径。但删除不是无条件安全的，因为仍有 204 个 Correct () Wrong transitions。

12.2 Retained 1,730 pairs: conditional diagnostic results

排除 670 个 Still Wrong pairs 后:

Metric	Control	Deletion	Change
Correct Answers	1,353 / 1,730	1,526 / 1,730	+173
Accuracy	78.21%	88.21%	+10.00 pp
Total Visible Tokens	460,979	401,802	-59,177
Mean Visible Tokens	266.46	232.26	-34.21
Median Visible Tokens	172	175	+3

Retained paired transitions:

Transition	Count	Share
Wrong () Correct	377	21.79%
Correct () Wrong	204	11.79%
Still Correct	1,149	66.42%

Deletion 在 retained cohort 中减少 12.84% total visible tokens, 但 median token saving 为 (-3), 即典型样本中 Deletion 反而略长。总 token 节省主要由少数大幅缩短的长尾 outputs 驱动。

具体分布为:

- Deletion 更短: 788;
- 相同长度: 34;
- Deletion 更长: 908。

因此, 不能只报告 mean 或 aggregate token saving。

12.3 四次 paired runs

Run	Retained n	Control Acc.	Deletion Acc.	Change	Wrong→Correct	Correct→Wrong	Token Saving Rate
1	433	77.83%	87.76%	+9.93 pp	96	53	8.98%
2	428	78.97%	89.72%	+10.75 pp	90	44	13.66%
3	432	79.86%	86.81%	+6.95 pp	87	57	14.89%
4	437	76.20%	88.56%	+12.36 pp	104	50	13.65%

四个 runs 的 improvement 均为正, 并且每个 run 都满足:

[>]

不过同一个 sample 出现在 4 次 runs 中, 因此这些 observations 不是完全独立。

12.4 Completion status

在 retained cohort 中:

Status	Control	Deletion	Net Change
Completed	1,656	1,701	+45
Cannot Continue	47	23	-24
Logical Break	27	6	-21

Deletion 使 abnormal states 从 74 降到 29, 但同时产生:

- 23 个新的 Cannot Continue;
- 6 个新的 Logical Break。

因此, aggregate completion improvement 不代表每个删除操作都安全。

12.5 Results by PRM rating

Retained cohort 中:

PRM Rating	Retained n	Control Acc.	Deletion Acc.	Change	Wrong→Correct	Correct→Wrong	Token Saving Rate
1	655	88.85%	88.09%	-0.76 pp	73	78	19.01%
0	613	85.15%	85.48%	+0.33 pp	91	89	11.03%
-1	462	53.90%	91.99%	+38.10 pp	213	37	4.83%

主要现象:

- rating (=1) 的 deletion gain 最大;
- rating (=1) 略微下降;
- rating (=0) 基本中性。

但 rating (=1) 中有 338/800, 即 42.25% 的 pairs 被排除为 Still Wrong, 明显高于其他 rating。因此 retained cohort 中的 91.99% Deletion Accuracy 不能解释为全量数据上的绝对性能。

12.6 Results by Step Type

Initial labels

Step Type	Retained n	Control Acc.	Deletion Acc.	Change	Wrong→Correct	Correct→Wrong
Essential	494	86.23%	84.62%	-1.61 pp	68	76
Redundant	665	88.12%	89.47%	+1.35 pp	79	70
Harmful	571	59.72%	89.84%	+30.12 pp	230	58

Human-calibrated labels

Step Type	Retained n	Control Acc.	Deletion Acc.	Change	Wrong→Correct	Correct→Wrong	Token Saving Rate
Essential	634	84.86%	87.38%	+2.52 pp	96	80	16.44%
Redundant	630	86.03%	87.78%	+1.75 pp	88	77	10.09%
Harmful	466	58.58%	89.91%	+31.33 pp	193	47	11.86%

Harmful 在两种 annotation version 下都表现出最强、最稳定的 deletion gain。

Essential 在 human-calibrated broad average 下为正, 并不意味着所有 Essential steps 都可以安全删除。Broad class average 会混合不同 rating、位置、问题难度和 continuation recoverability, 因此必须结合细分 diagnostic groups 分析。

12.7 关键 Rating × Step Type diagnostic groups

Human-calibrated labels

Diagnostic Group	Retained n	Control Acc.	Deletion Acc.	Change	Wrong→Correct	Correct→Wrong	Token Saving Rate
Rating (0) × Essential	163	91.41%	82.21%	-9.20 pp	14	29	17.48%
Rating (1) × Redundant	227	89.87%	88.11%	-1.76 pp	23	27	15.69%
Rating (-1) × Harmful	350	52.57%	90.86%	+38.29 pp	166	32	5.50%

这些结果构成项目最重要的证据:

Rating (0) × Essential

Neutral local quality 不等于 deletion safety。即使 token saving 较高，删除后准确率仍下降 9.20 pp。

Rating (1) × Redundant

正确且冗余的步骤更接近 compression candidate，但 human-calibrated result 仍为轻微负向，因此不能作为无条件删除规则。

Rating (-1) × Harmful

删除收益最强，支持 “错误步骤形成 reasoning anchor” 的假设。

12.8 Removable classifier

Human calibration 后：

Metric	Initial	Human-Calibrated	Change
Accuracy	50.00%	60.17%	+10.17 pp
Precision	90.35%	88.86%	-1.49 pp
Recall	48.49%	62.71%	+14.22 pp
Specificity	61.27%	41.18%	-20.09 pp
F1-score	63.11%	73.53%	+10.42 pp

Human calibration 主要提升 Recall 和 F1-score，但降低 Specificity。

在 retained cohort 中，human-calibrated predicted-removable group 仍包含 120 个 dangerous false-positive pairs。因此，该 classifier 更适合：

- candidate ranking;
- high-recall screening;
- verified deletion pipeline;

而不适合直接执行不可逆删除。

12.9 分层 Target-Step Cluster Bootstrap 结果

为避免把同一 target step 的 4 次重复运行视为相互独立，本节以 step_id 为聚类单位进行 5,000 次 cluster bootstrap。每次从 600 个 target steps 中有放回抽取 600 个 steps，并保留入选 step 的全部 4 次 runs。表中的 accuracy change 为 Deletion Accuracy 减去 Control Accuracy，单位为百分点；括号内为 percentile 95% confidence interval。Wrong → Correct 和 Correct → Wrong 为原始 2,400 pairs 中的观测数量。

长度分组在 step 层面按排名三等分，每组 200 个 target steps：

- step_length：Control prompt tokens 与 Deletion prompt tokens 的差值；
- prefix_length：删除目标 step 后实际可见输入的 prompt tokens；
- 分位数边界出现相同 token 长度时，以 sampleId 作确定性排序。

分组维度	分组	定义	Target steps	Pairs	Accuracy change (pp)	Wrong → Correct	Correct → Wrong
step position	Early	early	201	804	-8.98 ([-1.13, 11.18])	127	87
step position	Middle	middle	201	804	+9.45 ([3.31, 15.59])	144	68
step position	Late	late	198	792	+7.20 ([1.75, 12.62])	106	49
step length	Short	rank 1–200; 4–27 tokens	200	800	+0.25 ([-5.21, 5.56])	72	70
step length	Middle	rank 201–400; 27–40 tokens	200	800	+9.63 ([3.51, 15.66])	148	71
step length	Long	rank 401–600; 40–648 tokens	200	800	+11.75 ([5.53, 17.97])	157	63
prefix length	Short	rank 1–200; 272–431 tokens	200	800	-0.38 ([-0.68, 11.33])	121	78
prefix length	Middle	rank 201–400; 432–577 tokens	200	800	+10.88 ([4.75, 16.90])	155	68
prefix length	Long	rank 401–600; 578–1,229 tokens	200	800	+5.38 ([0.00, 10.81])	101	58
control correct frequency	0/4	4 次 Control 均错误	224	+33.37 ([27.52, 39.20])		299	0
control correct frequency	1/4	4 次中 1 次正确	23	+19.22 ([-1.25, 32.29])		28	14
control correct frequency	2/4	4 次中 2 次正确	27	-9.26 ([-8.93, 26.25])		31	21
control correct frequency	3/4	4 次中 3 次正确	28	-15.26 ([-20.69, 8.33])		19	25
control correct frequency	4/4	4 次 Control 均正确	298	-12.08 ([-15.49, -8.91])		0	144

主要发现：

1. **位置异质性。** Middle 和 Late 位置的删除收益显著为正；Early 的区间跨越 0，说明早期删除的平均收益更不稳定。
2. **目标 step 长度异质性。** Short steps 的平均效应接近 0；Middle 和 Long steps 的删除收益分别为 (+9.63) pp 和 (+11.75) pp。该关系是描述性关联，不能单独解释为长度的因果作用。
3. **Prefix length 呈非单调关系。** Middle-prefix 组收益最大；Long-prefix 组的区间下界四舍五入后为 0.00 pp。
4. **Control 稳定性是最强的分层变量。** 对 4 次 Control 均错误的 steps，删除带来 (+33.37) pp；对 4 次 Control 均正确的 steps，删除造成 (-12.08) pp。这说明删除收益高度依赖于 baseline solvability。

12.10 Length-Matched Placebo Deletion 结果

12.10.1 Placebo 选择与运行

Placebo 实验用于比较 “删除目标 step” 与 “删除同一轨迹中长度相近的其他 step”：

- 1. 使用 Qwen/Qwen3-8B 官方 tokenizer 计算轨迹中每个 step 的 token 长度；
- 2. 对每个 target step，筛选长度位于目标长度 (0.8) 至 (1.2) 的非目标 steps；
- 3. 使用固定随机种子，从合格 candidates 中最多抽取 4 个 Placebo steps；
- 4. 若 candidates 少于 4 个则全部使用；若没有 candidate，则跳过该 target step；
- 5. 每个 Placebo step 单独删除一次，从该 Placebo 所在位置之前的 prefix 重新生成 continuation；
- 6. 使用与主实验相同的 qwen/qwen3-8b judge 判断最终答案是否正确。

600 个 target steps 中，511 个至少有 1 个合格 Placebo，89 个因无长度匹配 candidate 被跳过。最终共运行 1,514 次 Placebo Deletion。每个 target step 先计算：

[= {r=1}^{(4)Y}{\{ir\}, }
[= {r=1}^{(4)Y}{\{ir\}, }
[= {k=1}^{(K_i)Y}{\{ik\}, K_i\{1,2,3,4\}.]

随后定义：

[= - ,]
[= - ,]
[= - .]

三个效应均先在 target-step 层面计算，再在各报告组内以 step_id 有放回重采样 5,000 次。下表单位为百分点，括号内为 percentile 95% confidence interval。

Group	Eligible	target steps	Placebo runs	Target Effect	Placebo Effect	Pure	Semantic Effect
Overall		511	1,514	+7.97 ([4.26, 11.69])	-0.57 ([-4.13, 3.13])		+8.55 ([4.83, 12.17])
rating (= -1)		169	458	+22.78 ([16.12, 29.59])	+9.47 ([2.86, 15.93])		+13.31 ([6.71, 19.53])
rating (= 0)		176	539	+0.99 ([-5.40, 7.39])	-5.63 ([-12.12, 0.76])		+6.63 ([0.19, 13.21])
rating (= 1)		166	517	+0.30 ([-5.27, 5.87])	-5.42 ([-11.19, 0.70])		+5.72 ([-0.05, 11.40])
Step Type = Harmful		201	563	+18.41 ([11.94, 24.88])	+3.57 ([-2.57, 9.74])		+14.84 ([8.83, 20.61])
rating (= -1) × Harmful		151	399	+23.84 ([16.89, 30.96])	+9.99 ([2.92, 17.00])		+13.85 ([6.95, 20.64])

主要发现：

- 1. **总体目标效应主要来自 target-specific component。** Overall Placebo Effect 接近 0 且区间跨越 0，而 Pure Semantic Effect 为 (+8.55) pp，95% CI 为 ([4.83, 12.17])。
- 2. **低评分步骤同时包含一般删除收益和目标语义收益。** rating (= -1) 的 Placebo Effect 为 (+9.47) pp，但扣除该基线后，Pure Semantic Effect 仍为 (+13.31) pp。
- 3. **Harmful label 提供独立的 target-specific signal。** Harmful steps 的 Pure Semantic Effect 为 (+14.84) pp。
- 4. **关键组结果稳定。** rating (= -1) × Harmful 的 Target Effect 为 (+23.84) pp，其中 Placebo Effect 为 (+9.99) pp，Pure Semantic Effect 仍达到 (+13.85) pp。
- 5. **rating (= 0) 的分解值得进一步检查。** 其原始 Target Effect 接近 0，但 Placebo baseline 为负，因此 Pure Semantic Effect 为 (+6.63) pp，区间下界仅略高于 0。

需要谨慎解释 Placebo Effect：Placebo step 在其自身位置被删除，因此它不仅反映长度匹配，还可能包含删除位置、可见 prefix 长度和 Placebo step 自身语义的影响。它是一个 **length-matched operational deletion baseline**，不能视为已经完全隔离的 “纯长度因果效应”。此外，Placebo 结果仅适用于 511 个有合格匹配项的 target steps；由于 89 个 steps 被排除，表中的 Target Effect 与全量 600-step 主分析不必完全一致。

13. 统计分析计划

13.1 Clustered uncertainty estimation

由于每个 target step 被重复运行 4 次，不能将 2,400 pairs 视为完全独立样本。

主分析应采用 target-step-level cluster bootstrap:

1. 以 600 个 target steps 为采样单位;
2. 每次有放回抽取 600 个 steps;
3. 保留每个 step 的全部 4 次 runs;
4. 重新计算 accuracy change、harm rate、recovery rate 和 token change;
5. 重复 1,000–10,000 次;
6. 报告 95% confidence interval。

本版本已完成 5,000 次 target-step cluster bootstrap; 主分层结果见第 12.9 节, Placebo effect decomposition 见第 12.10 节。

13.2 McNemar test

标准 McNemar test 可作为辅助结果，但由于未建模 sample-level clustering，不应将极小的 p-value 作为主要证据。

13.3 Stratified analysis

至少按以下因素分层:

- PRM rating;
- Step Type;
- rating $\times$ Step Type;
- step position;
- step length;
- prefix length;
- problem difficulty;
- control correctness frequency。

目前已完成 step position、step length、prefix length 与 control correctness frequency 的分层 bootstrap; problem difficulty 仍留待后续分析。

14. 下一阶段实验

14.1 保留全量结果作为主分析

不能只报告排除 Still Wrong 后的数字。

最终报告应同时呈现:

1. 全量 2,400 pairs 的 unconditional effect;
2. retained 1,730 pairs 的 conditional diagnostic effect。

14.2 Placebo deletion: 已完成, 待扩展

本版本已经完成第三种条件:

- Control: 保留目标步骤;
- Target Deletion: 删除目标步骤;
- Placebo Deletion: 删除同一轨迹中长度为目标 step (0.8)–(1.2) 的非目标 step。

已完成结果见第 12.10 节。后续扩展重点为:

- 进一步匹配 Placebo 与 target 的位置及 prefix length;
- 使用多个随机种子重复 Placebo 选择;
- 对无合格 Placebo 的 89 个 target steps 分析 selection bias;
- 使用不同 generator 和 judge 复现 effect decomposition。

14.3 Judge calibration

随机抽取 100–200 个 generation outputs 进行人工核验, 报告:

- judge–human agreement;
- false-positive rate;
- false-negative rate;
- 模糊等价案例。

优先使用:

1. final-answer extraction;
2. exact match;

- 3. symbolic equivalence;
- 4. 仅在无法自动判断时使用 LLM judge。

14.4 跨模型验证

在计算资源允许时，选择部分样本在第二个 generator 上复现：

- 验证 PRM rating $\times$ contribution mismatch 是否跨模型存在；
- 检查 Harmful deletion gain 是否依赖于 Qwen3-8B；
- 检查不同模型的 recoverability 是否不同。

14.5 多步骤删除

当前项目研究单步删除。若单步结果稳定，可进一步探索：

- 连续删除多个 Redundant steps；
- 逐步删除多个 Harmful steps；
- 删除顺序；
- cumulative token saving；
- error accumulation；
- rollback policy。

15. 预期贡献

1. 明确区分 Step Correctness 与 Step Contribution

说明局部正确性不能直接等价于下游必要性。

2. 提出 reasoning-step removability 的反事实操作化定义

通过 Control/Deletion paired continuation 实际测量步骤的 contextual contribution。

3. 系统刻画 PRM rating 与 removability 的关系

证明 PRM rating 有预测价值，但存在显著 off-diagonal cases。

4. 识别最有价值和最危险的 deletion groups

- 最有价值：rating (-1) $\times$ Harmful；
- 最危险：rating (0) $\times$ Essential；
- 需验证的压缩候选：rating (1) $\times$ Redundant。

5. 为 reasoning-step pruning 提供设计原则

未来 pruning system 应采用：

[+ + +]

而不是仅依赖单一 PRM threshold。

16. 局限性

16.1 Intervention 不是固定轨迹机械删除

模型会重新生成 continuation，因此测到的是 contextual contribution 与 model recoverability 的结合。

16.2 生成模型和 judge 属于同一模型家族

这可能引入自偏好，需要人工校准或不同 judge 验证。

16.3 Still Wrong filtering 存在 outcome-based selection

Retained cohort 适合 diagnostic analysis，但不能替代全量 treatment effect。

16.4 AI annotation 不能视为 ground truth

Human-calibrated labels 仍然依赖 few-shot AI classification，需要更多人工一致性检查。

16.5 Broad Step Type 不能保证 individual deletion safety

即使某个类别平均表现良好，单个步骤仍可能产生危险删除。

16.6 Placebo matching 尚未完全隔离长度机制

Placebo 仅按 step token length 匹配，并在 Placebo 自身位置执行删除，因此 target 与 Placebo 的 step position、visible prefix length 可能不同。当前 Placebo Effect 应解释为 length-matched operational baseline，而不是纯长度因果效应。与此同时，无合格匹配项的 89 个 target steps 未进入 Placebo 分析，可能产生 matched-cohort selection bias。

17. 时间安排

Week 1: 数据与统计修正

- 同时整理 full cohort 与 retained cohort;
- 实现 target-step-level cluster bootstrap;
- 检查重复问题和重复轨迹;
- 重新计算各分组置信区间。

Week 2: Judge calibration

- 人工核验 100–200 个 outputs;
- 比较 exact match、symbolic judge 和 LLM judge;
- 修正误判样本。

Week 3: Placebo deletion

- 构造 length-matched random deletion;
- 运行小规模 pilot;
- 比较 target-specific effect。

Week 4: 扩展实验

- 按位置、长度和难度分层;
- 分析 unstable samples;
- 选择部分样本进行第二模型复现。

Week 5: 图表与案例分析

- 整理主要表格;
- 选取典型 Essential、Redundant、Harmful 案例;
- 展示正确但冗余、低分但必要、错误且有害的案例。

Week 6: 论文或技术报告写作

- 完成方法、实验和局限性;
 - 明确 full 与 retained 两种口径;
 - 整理代码、数据和复现实验说明。
-

18. 推荐图表

1. 实验流程图

Sampling → Annotation → Human Calibration → Paired Deletion → Answer Evaluation → Statistical Analysis

2. 全量 Control 与 Deletion accuracy 对比

3. 四种 paired transition 堆叠图

4. Full cohort 与 retained cohort 对比图

5. PRM rating × Step Type heatmap

6. 三个 diagnostic groups 的 accuracy change 图

- (0) Essential
- (1) Redundant
- (−1) Harmful

7. Token saving distribution

- Mean
- Median
- Shorter / Same / Longer counts

8. Completion status transition 图

9. Human calibration 前后 classifier metrics

10. Target deletion 与 placebo deletion 对比

19. 预期结论

本项目预计得出以下结论：

PRM rating 与 reasoning-step contribution 存在明显关联，但它们是相关而不等价的两个概念。

PRM rating 可以作为步骤筛选和候选排序的先验信号，但不能直接作为自动删除规则。

删除收益主要集中在 Harmful steps，尤其是 rating ($=-1$) 且被识别为 Harmful 的步骤。此类步骤可能将模型锚定在错误推理路径上，删除后能够显著增加 Wrong () Correct transitions。

Redundant steps 的主要价值在于 compression，而不是稳定提升准确率。即使是 rating ($=1$) 的 Redundant steps，也需要 downstream validation。

Essential steps，尤其是 rating ($=0$) $\times$ Essential 的 off-diagonal cases，说明中性或不完美的局部评分并不代表步骤可被安全删除。

因此，一个可靠的 reasoning-step pruning system 应显式建模：

- Step Correctness;
 - Step Contribution;
 - Prediction Uncertainty;
 - Downstream Outcome;
 - Rollback Ability.
-

References

1. Hunter Lightman et al. Let' s Verify Step by Step. ICLR 2024.
2. OpenAI PRM800K.
3. Process Advantage Verifier, arXiv:2410.08146.
4. PRM-related reasoning evaluation work, arXiv:2504.16828.